

RELATÓRIO TÉCNICO: HealthSearch

Motor de Busca Híbrido com Okapi BM25, Busca Semântica Vetorial e Reciprocal Rank Fusion (RRF)

Instituição:	UNIPÊ - Centro Universitário de João Pessoa
Disciplina:	Tendências em Ciência da Computação
Docente:	Prof. Me. Ricardo Roberto de Lima
Equipe / Alunos:	- João Gabriel Barreto Falcão — Documentação - Júlio César Carvalho Santos — Desenvolvimento - Perilo Oliveira Viana Sobrinho — Desenvolvimento

1. Contextualização e Estudo de Caso

Métodos de busca exclusivamente léxicos falham diante do descasamento vocabular: termos frequentes na rotina (ex: "infarto" ou "ataque cardíaco") não coincidem exatamente com descrições formais (ex: "síndrome coronariana aguda"). Por outro lado, modelos vetoriais densos puros diluem a especificidade de termos literais críticos, tais como identificadores padronizados ("CÓD-ECG-12D") ou posologias de urgência. O HealthSearch resolve esse dilema técnico por meio de uma arquitetura híbrida que combina o algoritmo léxico Okapi BM25 com a Busca Semântica Vetorial, unificando as ordenações pelo método Reciprocal Rank Fusion (RRF) sob uma interface interativa em Streamlit.

2. Arquitetura da Solução

O pipeline do sistema é estruturado de forma modular em quatro etapas essenciais, contando com uma camada bônus de re-ranking neural:

2.1 Ingestão e Pré-processamento do Corpus Clínico

O corpus médico hardcoded (6 diretrizes de emergência) é submetido a um pipeline de limpeza textual: conversão uniforme para caracteres minúsculos, preservação de hifens em identificadores clínicos fundamentais (ex: cód-ecg-12d), eliminação de pontuação desnecessária e remoção de *stopwords* da língua portuguesa com suporte à biblioteca NLTK.

2.2 Motor Léxico Okapi BM25 e Calibração Dinâmica

A pontuação léxica é implementada através da biblioteca rank_bm25. O cálculo equilibra a frequência inversa do documento (\$IDF\$) com a saturação de frequência do termo e o comprimento relativo do documento em relação à média do corpus (\$avgdl\$):

$$BM25_Score(D, Q) = \sum [IDF(q_i) * (f(q_i, D) * (k1 + 1)) / (f(q_i, D) + k1 * (1 - b + b * (|D| / avgdl)))]$$

A barra lateral do aplicativo expõe dois controles deslizantes (*sliders*) para calibração dinâmica:

- **Parâmetro k (0.0 a 3.0, padrão 1.2):** Estabelece o limite de saturação da frequência do termo, prevenindo que repetições desmedidas distorçam o ranking.
- **Parâmetro b (0.0 a 1.0, padrão 0.75):** Define o grau de penalização para documentos extensos frente à média do acervo.

2.3 Motor Semântico Vetorial

Para superar variações de vocabulário e sinônimos médicos, consultas e documentos são mapeados em vetores densos através de Sentence-Transformers (modelo multilíngue MiniLM). O score semântico decorre do cálculo de Similaridade de Cosseno:

$$\text{Similaridade_Cosseno}(q, d) = (q \cdot d) / (||q|| * ||d||)$$

2.4 Algoritmo Híbrido de Fusão RRF (Reciprocal Rank Fusion)

Considerando que scores de BM25 e Similaridade de Cosseno provêm de distribuições numéricas incomparáveis, o método RRF unifica os ranqueamentos baseando-se nas posições relativas dos itens, neutralizando distorções provocadas por valores extremos:

$$\text{Score_RRF}(D) = \alpha * [1 / (k_rrf + \text{Rank_BM25}(D))] + (1 - \alpha) * [1 / (k_rrf + \text{Rank_Semantico}(D))]$$

Adota-se a constante de suavização $k_{\text{rrf}} = 60$, com slider interativo para o peso α entre \$0.0\$ (estritamente semântico) e \$1.0\$ (estritamente léxico), operando em $\alpha = 0.5$ no equilíbrio padrão.

2.5 Bônus: Re-ranking Neural com Cross-Encoder (+0.3 Pts)

Ativado via *checkbox* na interface, um modelo Cross-Encoder calcula a atenção bidirecional profunda entre a consulta e os Top-3 candidatos resultantes da fusão RRF, oferecendo um refinamento final de alta precisão.

3. Diagnóstico Experimental e Comparativo de Ranks

A eficácia da fusão híbrida foi validada a partir da execução de dois cenários clínicos representativos:

Consulta Teste	Motor Léxico (BM25)	Motor Semântico Vetorial	Híbrido RRF
"CÓD-ECG-12D" (Código Técnico Exato)	Excelente (Top-1 / Top-2): Recupera os Docs 1 e 6 de forma precisa por correspondência exata do token.	Deficiente: Vetores densos diluem a string exata, recuperando trechos amplos de UTI e arritmias.	Ótimo: Mantém os Docs 1 e 6 no topo sem dispersão de resultados.

Consulta Teste	Motor Léxico (BM25)	Motor Semântico Vetorial	Híbrido RRF
"ataque cardíaco e infarto" (Sinonímia Clínica)	Falha Crítica: Localiza apenas o Doc 2 (presença literal de 'infarto'); desconsidera o Doc 1.	Excelente: Associa semanticamente com "síndrome coronariana" (Doc 1) e com o Doc 2.	Ótimo: Unifica ambos os documentos clínicos relevantes nas primeiras colocações.

3.1 Organização das Abas na Interface Streamlit

- **Aba 1 (Motor BM25):** Tabela com ranking ordenado por score léxico puro.
- **Aba 2 (Motor Semântico):** Ordenação vetorial classificada por similaridade de cosseno.
- **Aba 3 (Híbrido RRF):** Ranqueamento combinado ponderado pelo slider α .
- **Aba 4 (Matriz Comparativa):** Tabela consolidada ilustrando a transição de posições entre os métodos.
- **Aba 5 (Cross-Encoder):** Reordenação contextual refinada do Top-3 candidatos.

4. Divisão de Tarefas da Equipe

Membro da Equipe	Papel	Atribuições Principais
João Gabriel Barreto Falcão	Documentação	Elaboração do relatório técnico em PDF, consolidação dos testes comparativos e documentação conceitual da solução.
Júlio César Carvalho Santos	Desenvolvimento	Construção da interface interativa em Streamlit (abas comparativas, sidebar), integração RRF e módulo Cross-Encoder.
Perilo Oliveira Viana Sobrinho	Desenvolvimento	Implementação do motor BM25, calibração dinâmica de k_1 e b , e cálculo da similaridade vetorial por embeddings.

5. Conclusões e Considerações Finais

A realização do HealthSearch comprova na prática que a busca híbrida é o padrão ideal para recuperação de informações médicas. Enquanto o BM25 preserva a precisão indispensável para códigos e dosagens exatas, a busca vetorial densa assegura a cobertura de terminologias clínicas equivalentes. A fusão RRF sintetiza de forma equilibrada ambos os motores, mitigando pontos cegos críticos e proporcionando maior segurança à tomada de decisões em emergências hospitalares.