

# RELATÓRIO TÉCNICO: HealthSearch

## Motor de Busca Híbrido com Okapi BM25, Busca Semântica Vetorial e Reciprocal Rank Fusion (RRF)

|                  |                                                                                                                                                                                         |
|------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Instituição:     | UNIPÊ - Centro Universitário de João Pessoa                                                                                                                                             |
| Disciplina:      | Tendências em Ciência da Computação                                                                                                                                                     |
| Docente:         | Prof. Me. Ricardo Roberto de Lima                                                                                                                                                       |
| Equipe / Alunos: | <ul style="list-style-type: none"><li>• <b>Júlio César Carvalho Santos</b> — Desenvolvimento e documentação</li><li>• <b>Perilo Oliveira Viana Sobrinho</b> — Desenvolvimento</li></ul> |

### 1. Contextualização e Estudo de Caso

Métodos de busca exclusivamente léxicos falham diante do descasamento vocabular: termos frequentes na rotina (ex: "infarto" ou "ataque cardíaco") não coincidem exatamente com descrições formais (ex: "síndrome coronariana aguda"). Por outro lado, modelos vetoriais densos puros diluem a especificidade de termos literais críticos, tais como identificadores padronizados ("CÓD-ECG-12D") ou posologias de urgência. O HealthSearch resolve esse dilema técnico por meio de uma arquitetura híbrida que combina o algoritmo léxico Okapi BM25 com a Busca Semântica Vetorial, unificando as ordenações pelo método Reciprocal Rank Fusion (RRF) sob uma interface interativa em Streamlit.

### 2. Arquitetura da Solução

O pipeline do sistema é estruturado de forma modular em quatro etapas essenciais, contando com uma camada bônus de re-ranking neural:

#### 2.1 Ingestão e Pré-processamento do Corpus Clínico

O corpus médico hardcoded (6 diretrizes de emergência) é submetido a um pipeline de limpeza textual: conversão uniforme para caracteres minúsculos, preservação de hifens em identificadores clínicos fundamentais (ex: cód-ecg-12d), eliminação de pontuação desnecessária e remoção de *stopwords* da língua portuguesa com suporte à biblioteca NLTK.

#### 2.2 Motor Léxico Okapi BM25 e Calibração Dinâmica

A pontuação léxica é implementada através da biblioteca rank\_bm25. O cálculo equilibra a frequência inversa do documento (\$IDF\$) com a saturação de frequência do termo e o comprimento relativo do documento em relação à média do corpus (\$avgdl\$):

$$BM25\_Score(D, Q) = \sum [ IDF(q_i) * (f(q_i, D) * (k1 + 1)) / (f(q_i, D) + k1 * (1 - b + b * (|D| / avgdl))) ]$$

A barra lateral do aplicativo expõe dois controles deslizantes (*sliders*) para calibração dinâmica:

- **Parâmetro k<sub>i</sub> (0.0 a 3.0, padrão 1.2):** Estabelece o limite de saturação da frequência do termo, prevenindo que repetições desmedidas distorçam o ranking.
- **Parâmetro b (0.0 a 1.0, padrão 0.75):** Define o grau de penalização para documentos extensos frente à média do acervo.

## 2.3 Motor Semântico Vetorial

Para superar variações de vocabulário e sinônimos médicos, consultas e documentos são mapeados em vetores densos através de Sentence-Transformers (modelo multilíngue MiniLM). O score semântico decorre do cálculo de Similaridade de Cosseno:

$$\text{Similaridade\_Cosseno}(q, d) = (q \cdot d) / (||q|| * ||d||)$$

## 2.4 Algoritmo Híbrido de Fusão RRF (Reciprocal Rank Fusion)

Considerando que scores de BM25 e Similaridade de Cosseno provêm de distribuições numéricas incomparáveis, o método RRF unifica os ranqueamentos baseando-se nas posições relativas dos itens, neutralizando distorções provocadas por valores extremos:

$$\text{Score\_RRF}(D) = \alpha * [ 1 / (k\_rrf + \text{Rank\_BM25}(D)) ] + (1 - \alpha) * [ 1 / (k\_rrf + \text{Rank\_Semantico}(D)) ]$$

Adota-se a constante de suavização  $k_{\text{rrf}} = 60$ , com slider interativo para o peso  $\alpha$  entre \$0.0\$ (estritamente semântico) e \$1.0\$ (estritamente léxico), operando em  $\alpha = 0.5$  no equilíbrio padrão.

## 2.5 Bônus: Re-ranking Neural com Cross-Encoder (+0.3 Pts)

Ativado via *checkbox* na interface, um modelo Cross-Encoder calcula a atenção bidirecional profunda entre a consulta e os Top-3 candidatos resultantes da fusão RRF, oferecendo um refinamento final de alta precisão.

# 3. Diagnóstico Experimental e Comparativo de Ranks

A eficácia da fusão híbrida foi validada a partir da execução de dois cenários clínicos representativos:

| Consulta Teste                                 | Motor Léxico (BM25)                                                                                              | Motor Semântico Vetorial                                                                                   | Híbrido RRF                                                                |
|------------------------------------------------|------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------|
| <b>"CÓD-ECG-12D"</b><br>(Código Técnico Exato) | <b>Excelente (Top-1 / Top-2):</b><br>Recupera os Docs 1 e 6 de forma precisa por correspondência exata do token. | <b>Deficiente:</b><br>Vetores densos diluem a string exata, recuperando trechos amplos de UTI e arritmias. | <b>Ótimo:</b><br>Mantém os Docs 1 e 6 no topo sem dispersão de resultados. |

| Consulta Teste                                     | Motor Léxico (BM25)                                                                                     | Motor Semântico Vetorial                                                                      | Híbrido RRF                                                                                |
|----------------------------------------------------|---------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------|
| "ataque cardíaco e infarto"<br>(Sinónímia Clínica) | <b>Falha Crítica:</b><br>Localiza apenas o Doc 2 (presença literal de 'infarto'); desconsidera o Doc 1. | <b>Excelente:</b><br>Associa semanticamente com "síndrome coronariana" (Doc 1) e com o Doc 2. | <b>Ótimo:</b><br>Unifica ambos os documentos clínicos relevantes nas primeiras colocações. |

### 3.1 Organização das Abas na Interface Streamlit

- **Aba 1 (Motor BM25):** Tabela com ranking ordenado por score léxico puro.
- **Aba 2 (Motor Semântico):** Ordenação vetorial classificada por similaridade de cosseno.
- **Aba 3 (Híbrido RRF):** Ranqueamento combinado ponderado pelo slider  $\alpha$ .
- **Aba 4 (Matriz Comparativa):** Tabela consolidada ilustrando a transição de posições entre os métodos.
- **Aba 5 (Cross-Encoder):** Reordenação contextual refinada do Top-3 candidatos.

## 4. Divisão de Tarefas da Equipe

| Membro da Equipe               | Papel                                 | Atribuições Principais                                                                                                                                      |
|--------------------------------|---------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Júlio César Carvalho Santos    | <b>Desenvolvimento e documentação</b> | Construção da interface interativa em Streamlit (abas comparativas, sidebar), integração RRF, módulo Cross-Encoder e elaboração do relatório técnico em PDF |
| Perilo Oliveira Viana Sobrinho | <b>Desenvolvimento</b>                | Implementação do motor BM25, calibração dinâmica de $k_1$ e $b$ , e cálculo da similaridade vetorial por embeddings.                                        |

## 5. Conclusões e Considerações Finais

A realização do HealthSearch comprova na prática que a busca híbrida é o padrão ideal para recuperação de informações médicas. Enquanto o BM25 preserva a precisão indispensável para códigos e dosagens exatas, a busca vetorial densa assegura a cobertura de terminologias clínicas equivalentes. A fusão RRF sintetiza de forma equilibrada ambos os motores, mitigando pontos cegos críticos e proporcionando maior segurança à tomada de decisões em emergências hospitalares.